Научно-исследовательский университет
“Высшая школа экономики”

Школа информатики, физики и технологий

Прикладной анализ данных и искусственный интеллект

Повышение качества решения математических задач олимпиадного уровня с помощью LLM с открытыми весами

Костерин Михаил Георгиевич
научный руководитель: Зубаков Алексей Васильевич,
старший разработчик ООО “ИННОВЕЙТИВ ПИПЛ”

Предметная область

В работе рассматривается применение LLM к задачам олимпиадной математики.

При решении могут быть полезны:

- точная арифметика и вычисления по модулю;
- небольшой перебор вариантов;
- символьные и численные проверки.

Для этого используется TiR:

модель решает задачу с возможностью вызывать Python.



Актуальность

Олимпиадная математика стала заметным полигоном для оценки reasoning-моделей: пример — соревнования AIMO.

В практическом режиме важны не только правильные ответы, но и краткость генераций. Более короткие генерации позволяют:

- при фиксированном числе попыток снизить стоимость инференса;
- при фиксированном бюджете получить больше независимых попыток и повысить устойчивость итогового ответа.

Цель и критерии оценки

Цель работы

Разработать и экспериментально оценить подход к RLVR-дообучению gpt-oss-20b для олимпиадных задач в TiR-режиме, а также исследовать возможность повышения токенной эффективности таких рассуждений.

Оценка проводится по:

- качеству: Maj@16, Pass@16, sample accuracy;
- стоимости: средняя длина генерации

Существующие подходы и новизна

Существующий подход	Что уже есть	Чего не хватает для этой постановки
TiR-RLVR (ReTool, ToRL)	обучение по проверяемому ответу в режиме с Python-инструментом	нет целевой оптимизации длины правильных траекторий
ShorterBetter	RLVR-модификация для поощрения коротких правильных решений	нужна адаптация к TiR-траекториям: текст + Python-код

Новизна работы

Объединение RLVR-дообучения в TiR-режиме с длино-ориентированной модификацией ShorterBetter.

Выбор базовой модели и наборы оценки

Наборы оценки

- Валидационный: 20 задач (AIMO + ВсОШ).
- Тестовый: 30 задач (IMO Shortlist 2024 + IMO 2025 + ВсОШ).
- Задачи адаптированы к формату автоматически проверяемого целочисленного ответа.
- Размеры наборов ограничены стоимостью многократного TiR-инференса.

Выбор базовой конфигурации на validation

Конфигурация	Maj@8	Средняя длина
gpt-oss-20b CoT	0.50	20 729
gpt-oss-20b TiR	**0.65**	**17 371**
Nemotron Nano 30B CoT	0.45	28 679
Nemotron Nano 30B TiR	0.30	29 597

Фиксированное условие оценки: контекстное окно 32K токенов.

Выбор постановки обучения

Решение	Выбрано
Тип дообучения	**RLVR-only**
RL-оптимизация	**GRPO-like**
Алгоритм	**DAPO**
Награда	**Бинарная по финальному ответу**

Экспериментальная конфигурация

- тренировочный датасет: Crystal-Math-Preview rewritten;
- LoRA rank = 32; LR = 1e−6
- размер группы = 8, 4 валидные группы на шаг;
- 50 шагов обучения, warmup = 10.

ShorterBetter

Из всех других методов сокращения длины был выбран потому что

- не требует дополнительных rollout'ов;
- совместим с GRPO-like обучением;
- не требует надежной оценки сложности задачи;
- сокращает уже используемую reasoning-траекторию, а не выбирает режим «думать / не думать»

Идея метода

SOL = min tokens(τ_i) среди правильных траекторий в группе
Ориентир длины — кратчайшее правильное решение среди rollout'ов одной задачи.

Адаптация к TiR

tokens(τ) = текст модели + Python-код
Python-output не включается в длину, потому что это внешнее наблюдение, а не действие модели.

Модифицированная награда

$$\text{reward} = \text{correctness} + \text{ORS} - \beta \cdot |\text{tokens}(\tau) - \text{SOL}|$$
$$\beta = 3.5e{-}5$$

Валидация: выбор чекпоинтов

DAPO

Чекпоинт	Maj@16	Средняя длина
dapo20	0.75	17 081
dapo30	0.75	17 928
dapo40	**0.85**	18 788
dapo50	0.80	20 193

ShorterBetter

Чекпоинт	Maj@16	Средняя длина
sb20	**0.80**	15 689
sb30	0.70	13 931
sb40	0.70	11 748
sb50	0.70	10 287

Дополнительные проверки

1. CoT-абляция

Модель	Maj@16	Средняя длина
dapo40 TiR-trained	**0.85**	**18 788**
dapo-cot40	0.75	25 248

2. sb50@24

Модель	k	Maj@k	Токены всего
sb20	16	**0.80**	5.02M
sb50	24	0.75	4.99M

3. Анализ весов после LoRA merge

Метрика	Максимум у dapo40	Максимум у sb20
Доля измененных элементов	down_proj: 57.9%	down_proj: 52.4%
Относительное L1-изменение	gate_up_proj: 1.417%	gate_up_proj: 1.413%

Финальная оценка

Модель	Maj@16	Pass@16	Sample acc.	Средняя длина
base	0.600	0.767	0.410	18 446
dapo40	**0.700**	0.767	0.427	19 911
sb20	0.667	0.767	**0.438**	**16 206**

Выводы

- В выбранной постановке gpt-oss-20b medium + TiR RLVR/DAPO повысил Maj@16, но увеличил среднюю длину генераций.
- Адаптация ShorterBetter к TiR-траекториям дала более экономичный компромисс: прирост качества относительно base сохранился, а средняя длина стала ниже base.

Заключение

Выполнено:

- Обоснован выбор базовой конфигурации: gpt-oss-20b medium + TiR.
- Сформированы validation/test наборы с автоматической проверкой ответа.
- Реализована RLVR/DAPO-постановка дообучения с LoRA.
- Адаптирован ShorterBetter к TiR-траекториям.
- Проведено сравнение base, DAPO и DAPO+ShorterBetter по качеству и средней длине.
- Выполнены дополнительные проверки: CoT-абляция, sb50@24, анализ LoRA merge.

Дальнейшая работа:

- Увеличение количества задач в тестовом и валидационном наборах.
- Подбор коэффициента β для ShorterBetter.

Репозиторий:

github.com/Mikefromtheback/diplomaimo